

Seleção Dinâmica de Algoritmos de Virtual Network Embedding usando XGBoost

Luis Antonio Momm Duarte

Programa de Pós-Graduação em Computação Aplicada
Universidade do Estado de Santa Catarina
Joinville, Brasil
luis.duarte@edu.udesc.br

Adriano Fiorese

Department of Computer Science
Santa Catarina State University
Joinville, Brazil
adriano.fiorese@udesc.br

Resumo—A crescente demanda por virtualização de redes em infraestruturas modernas de computação em nuvem tornou o Virtual Network Embedding (VNE) uma área crítica de pesquisa. Embora numerosos algoritmos de VNE tenham sido propostos, nenhum algoritmo único apresenta desempenho consistentemente superior em todos os cenários. Este trabalho propõe uma abordagem inovadora que utiliza aprendizado de máquina, especificamente XGBoost, para selecionar inteligentemente o algoritmo mais apropriado para cada requisição de rede virtual recebida. Resultados experimentais demonstram que o seletor dinâmico alcança 93,33% de acurácia na predição do melhor algoritmo, com taxa de aceitação de 43,33% e tempo médio de resolução de 5,63s, ficando apenas 1,67 pontos percentuais abaixo do oráculo teórico ótimo. O modelo identifica topologia e tamanho relativo da VNR como os fatores mais importantes para seleção de algoritmo, demonstrando melhorias estatisticamente significativas em relação a algoritmos baseline individuais.

Index Terms—Virtual Network Embedding, Machine Learning, XGBoost, Network Virtualization, Algorithm Selection

I. INTRODUÇÃO

A crescente demanda por virtualização de redes em infraestruturas modernas de computação em nuvem tornou o problema de Virtual Network Embedding (VNE) uma área crítica de pesquisa. O VNE aborda o problema de mapear requisições de redes virtuais (Virtual Network Requests - VNRs) sobre a infraestrutura de rede física, satisfazendo restrições de recursos e otimizando objetivos específicos como taxa de aceitação, utilização de recursos e consumo de energia.

Na última década, numerosos algoritmos de VNE foram propostos, variando desde métodos exatos baseados em Programação Inteira Mista (MIP) até abordagens heurísticas e meta-heurísticas. Algoritmos exatos como MIP garantem soluções ótimas mas sofrem com problemas de escalabilidade e altos custos computacionais. Métodos heurísticos como D-Rounding e RW-Rank-BFS oferecem tempos de execução mais rápidos, mas podem produzir alocações subótimas. Abordagens meta-heurísticas como Genetic Algorithms (GA), Particle Swarm Optimization (PSO) e Monte Carlo Tree Search (MCTS) tentam balancear qualidade da solução e tempo de execução, porém seu desempenho varia significativamente dependendo das características da instância do problema.

Apesar da extensa pesquisa em algoritmos de VNE, um desafio fundamental permanece: nenhum algoritmo único apresenta desempenho consistentemente superior em todos os

cenários de rede e características de carga de trabalho. Este fenômeno, conhecido como o teorema "No Free Lunch" em otimização, sugere que a escolha do melhor algoritmo é inerentemente dependente do problema. Abordagens tradicionais para implantação de VNE tipicamente selecionam um único algoritmo "bala de prata" para todas as requisições recebidas, independentemente de suas características ou do estado atual da rede física. Esta estratégia única para todos os casos falha em explorar os pontos fortes de diferentes algoritmos para diferentes cenários.

Por exemplo, VNRs pequenas com baixas demandas de recursos podem ser eficientemente tratadas por heurísticas rápidas, enquanto requisições maiores e mais complexas poderiam se beneficiar de métodos exatos ou meta-heurísticas. Similarmente, o estado atual da rede física, como fragmentação de recursos, capacidade disponível e topologia da rede, influencia significativamente qual algoritmo apresentará melhor desempenho.

Este trabalho propõe uma abordagem para VNE que utiliza aprendizado de máquina, especificamente XGBoost (Extreme Gradient Boosting), para selecionar inteligentemente o algoritmo mais apropriado para cada requisição de rede virtual recebida. Ao invés de um único algoritmo, o método proposto analisa as características de cada VNR e o estado atual da rede física para prever qual algoritmo produzirá os melhores resultados em termos de taxa de aceitação e tempo de solução. Esta estratégia de seleção adaptativa visa combinar os pontos fortes de múltiplos algoritmos, potencialmente alcançando melhor desempenho geral do que qualquer método individual.

As principais contribuições deste trabalho são:

- Um conjunto diverso de simulações utilizando a plataforma ViRNE, executando 7 diferentes algoritmos de VNE (exatos, heurísticos e meta-heurísticos) em topologias Tree e Fat-Tree com parâmetros variados e diferentes características de carga, resultando em 800 VNRs únicas para treinamento.
- Uma metodologia de engenharia de features que captura 17 características relevantes das VNRs e estados da rede física, incluindo métricas topológicas, demandas de recursos, capacidade disponível e indicadores de utilização.
- Um modelo de classificação baseado em XGBoost com otimização de hiperparâmetros via Grid Search,

alcançando 93,33% de acurácia e F1-score ponderado de 92,36% na predição do melhor algoritmo para cada requisição.

- Uma avaliação experimental comparando a abordagem de seleção dinâmica contra 7 algoritmos individuais e um oráculo teórico, demonstrando que o XGBoost alcança desempenho quase ótimo com apenas 1,67% de diferença em taxa de aceitação.
- Análise de importância de features revelando que topologia e tamanho relativo da VNR são os fatores mais críticos para seleção de algoritmo, permitindo interpretação sobre o processo de decisão.
- Reprodutibilidade completa com código fonte, dados de simulação e modelos treinados disponibilizados publicamente.

// todo verificar se isso está correto (mapeamento seção)

O restante deste artigo está organizado da seguinte forma. A Seção II apresenta o referencial teórico necessário para compreensão do problema de VNE e técnicas de aprendizado de máquina usando árvores de decisão, como o XGBoost. A Seção III revisa trabalhos relacionados em algoritmos de VNE e abordagens de seleção de algoritmos. A Seção IV descreve a metodologia proposta, incluindo o processo de geração de dados de simulação, extração de features, treinamento do modelo XGBoost e estratégia de avaliação. A Seção V apresenta os resultados experimentais, analisando a performance do seletor dinâmico em comparação com algoritmos baseline. Finalmente, a Seção VI conclui o artigo e delinea direções futuras de pesquisa.

II. REFERENCIAL TEÓRICO

A. Virtual Network Embedding

Virtual Network Embedding (VNE) é o processo de mapear requisições de redes virtuais sobre uma infraestrutura de rede física compartilhada, respeitando restrições de capacidade de recursos. Uma requisição de rede virtual $G_v = (N_v, L_v)$ consiste em um conjunto de nós virtuais N_v e enlaces virtuais L_v , em que cada nó e enlace possui demandas de recursos específicas (CPU, memória, banda). A rede física $G_p = (N_p, L_p)$ fornece os recursos computacionais e de rede para hospedar as VNRs.

O problema de VNE pode ser decomposto em dois subproblemas: (1) mapeamento de nós virtuais para nós físicos e (2) mapeamento de enlaces virtuais para caminhos na rede física. O objetivo é maximizar métricas como taxa de aceitação de VNRs, utilização de recursos e receita do provedor, enquanto minimiza custos operacionais e tempo de processamento.

O VNE é conhecido por ser NP-difícil mesmo em casos simplificados [1], motivando o desenvolvimento de diversas classes de algoritmos:

Algoritmos Exatos: Formulações baseadas em Programação Linear Inteira (ILP) ou Programação Inteira Mista (MIP) garantem soluções ótimas mas possuem complexidade exponencial. São práticos apenas para instâncias pequenas devido ao tempo de resolução proibitivo para larga escala.

Heurísticas: Algoritmos gulosos que tomam decisões locais baseadas em rankings de nós ou estratégias de busca. Exemplos incluem NodeRank, D-Rounding e algoritmo de busca de caminho. Oferecem tempo de execução rápido mas qualidade de solução variável.

Meta-heurísticas: Técnicas de busca estocástica como algoritmos genéticos (GA), Particle Swarm Optimization (PSO), Simulated Annealing (SA) e Monte Carlo Tree Search (MCTS). Balanceiam exploração do espaço de busca, oferecendo trade-off entre qualidade e tempo.

B. XGBoost

XGBoost (Extreme Gradient Boosting) é um algoritmo de aprendizado de máquina, de código aberto, baseado em conjunto de modelos de árvores de decisão que utiliza a técnica de gradient boosting. O algoritmo constrói modelos preditivos de forma iterativa, em que cada nova árvore corrige os erros das árvores anteriores.

O XGBoost otimiza uma função objetivo que combina uma função de perda (loss function) com termos de regularização para prevenir overfitting:

- **Desempenho:** Implementação eficiente com otimizações como paralelização, cache-aware access e out-of-core computing
- **Regularização:** Penalização de complexidade do modelo (L1 e L2) previne overfitting
- **Handling de Dados Esparsos:** Tratamento eficiente de valores faltantes
- **Interpretabilidade:** Métricas de importância de features facilitam análise do modelo
- **Flexibilidade:** Suporta classificação multiclasse, regressão e ranking

Para problemas de classificação multiclasse, o XGBoost utiliza softmax para computar probabilidades de classe e otimiza a função de cross-entropy. Além disso, o algoritmo é bastante utilizado em estudos de aprendizado de máquina, fornecendo ampla documentação e bibliotecas prontas para seu uso, motivando a escolha.

C. Seleção de Algoritmos

A seleção de algoritmos pode ser formulada como um problema de aprendizado supervisionado, onde o objetivo é aprender uma função de mapeamento $f : \mathcal{F} \rightarrow \mathcal{A}$ que mapeia features de instância $\mathcal{F}$ para o melhor algoritmo $\mathcal{A}$.

No contexto de VNE, o problem space consiste em VNRs com diferentes tamanhos, topologias e demandas de recursos. O algorithm space inclui métodos exatos, heurísticos e meta-heurísticos. O feature space captura características da VNR e estado da rede física. O performance space é definido por métricas como taxa de aceitação e tempo de solução.

III. METODOLOGIA

Esta seção descreve a metodologia proposta para seleção dinâmica de algoritmos VNE usando XGBoost, incluindo o processo de geração de simulações, engenharia de features, treinamento do modelo e estratégia de avaliação.

A. Visão Geral da Abordagem

A abordagem proposta consiste em quatro etapas principais:

- 1) **Coleta de Dados:** Executar múltiplos algoritmos VNE em topologias variadas para coletar dados de desempenho
- 2) **Engenharia de Features:** Extrair características relevantes das VNRs e estado da rede física
- 3) **Treinamento do Modelo:** Otimizar hiperparâmetros do XGBoost e treinar classificador multiclasse
- 4) **Predição Online:** Para cada nova VNR, prever o melhor algoritmo e executá-lo

O fluxo operacional do sistema é o seguinte: quando uma nova VNR chega, suas características (número de nós, demandas de recursos, topologia) e o estado atual da rede física (utilização de recursos, número de VNRs ativas) são extraídos como features. O modelo XGBoost treinado prevê qual algoritmo deve ser utilizado. O algoritmo selecionado é então executado para tentar mapear a VNR sobre a rede física.

B. Geração de dados de simulações

Os dados foram coletados utilizando a plataforma ViRNE, executando simulações de VNE com 7 diferentes algoritmos em 2 topologias de datacenter: árvore binária e fat-tree. Os algoritmos avaliados incluem:

- **MIP:** Mixed Integer Programming (método exato)
- **GA-Meta:** Genetic Algorithm com meta-learning
- **PSO-Meta:** Particle Swarm Optimization com meta-learning
- **SA-Meta:** Simulated Annealing com meta-learning
- **MCTS:** Monte Carlo Tree Search
- **PL-Rank:** PageRank-based heuristic
- **RW-Rank-BFS:** Random Walk Rank com Breadth-First Search
- **D-Round:** Deterministic Rounding heuristic

As topologias utilizadas foram:

- **Tree:** Topologia hierárquica em árvore com 3 níveis // TODO quanto
- **Fat-Tree:** Topologia de datacenter com k=4 (16 servidores)

Para cada combinação de algoritmo e topologia, foram executadas 10 repetições com diferentes sementes aleatórias para garantir significância estatística. Cada simulação gerou aproximadamente 100 VNRs, totalizando 11.672 execuções de algoritmos. Após deduplicação (removendo múltiplas execuções da mesma VNR), obtivemos 800 VNRs únicas para treinamento.

Os parâmetros de geração de VNRs foram:

- Número de nós virtuais: 2 a 10 nós
- Probabilidade de conexão entre nós: 50%
- Demanda de CPU/recursos de nós: [0, 20] unidades
- Demanda de banda de enlaces: [0, 50] unidades
- Tempo de vida: distribuição exponencial com média de 500 unidades
- Taxa de chegada: processo de Poisson variável

A rede física possui:

- Capacidade de nós: [50, 100] unidades de CPU
- Capacidade de enlaces: [50, 100] unidades de banda

C. Engenharia de Features

Um dos aspectos mais críticos do trabalho foi a definição de features que capturam características relevantes das VNRs e estado da rede física. O conjunto final de features inclui 17 características divididas em quatro categorias:

Características da VNR (9 features):

- **v_net_num_nodes:** Número de nós virtuais
- **v_net_num_edges:** Número de enlaces virtuais
- **v_net_size_ratio:** Razão entre tamanho da VNR e rede física
- **v_net_demand_per_node:** Demanda média por nó
- **v_net_demand_per_enlace:** Demanda média por link
- **v_net_connectivity:** Densidade de conexões (edges/nodes)
- **v_net_total_demand:** Demanda total de recursos
- **v_net_node_to_enlace_demand_ratio:** Razão entre demanda de nós e links
- **v_net_lifetime:** Tempo de vida esperado da VNR

Estado da Rede Física (4 features):

- **p_net_available_resource:** Total de recursos disponíveis
- **p_net_node_util:** Utilização média dos nós físicos
- **p_net_enlace_util:** Utilização média dos links físicos
- **p_net_overall_util:** Utilização geral da rede

Estado do Sistema (3 features):

- **inservice_count:** Número de VNRs atualmente ativas
- **system_load:** Carga normalizada do sistema
- **num_running_p_net_nodes:** Número de nós físicos ativos

Contexto (1 feature):

- **topology_encoded:** Tipo de topologia (tree vs fat-tree)

D. Treinamento do Modelo XGBoost

O dataset de 800 VNRs foi dividido em três conjuntos:

- **Treino:** 560 VNRs (70%)
- **Validação:** 120 VNRs (15%)
- **Teste:** 120 VNRs (15%)

Os hiperparâmetros do XGBoost foram otimizados via Grid Search com validação cruzada de 4 folds. O espaço de busca incluiu:

- **max_depth:** [3, 5, 7, 10]
- **learning_rate:** [0.01, 0.05, 0.1, 0.2]
- **n_estimators:** [50, 100, 200, 300]
- **subsample:** [0.6, 0.8, 1.0]
- **colsample_bytree:** [0.6, 0.8, 1.0]

A melhor configuração encontrada foi:

- **max_depth:** 7
- **learning_rate:** 0.1
- **n_estimators:** 200
- **subsample:** 0.8

- `colsample_bytree`: 0.8

O modelo foi treinado para classificação multiclasse com objetivo de maximizar o F1-score ponderado. O tempo total de treinamento foi de aproximadamente 30 segundos em um laptop padrão, demonstrando eficiência computacional.

E. Métricas de Avaliação

O desempenho do seletor dinâmico foi avaliada usando múltiplas métricas:

Métricas de Classificação:

- **Acurácia:** Proporção de predições corretas
- **Matriz de Confusão:** Análise de erros de classificação

Métricas de Desempenho em Produção:

- **Taxa de Aceitação:** Porcentagem de VNRs aceitas com sucesso
- **Tempo Médio de Resolução:** Tempo médio para processar uma VNR
- **Diferença para o Oráculo:** Diferença de desempenho comparado ao melhor algoritmo possível (oráculo)

O **oráculo** representa um limite teórico superior, selecionando sempre o algoritmo que produziu o melhor resultado para cada VNR específica (conhecimento perfeito do futuro). Comparar contra o oráculo quantifica o "arrependimento" da estratégia de seleção.

IV. RESULTADOS EXPERIMENTAIS

Esta seção apresenta os resultados experimentais do seletor dinâmico de algoritmos XGBoost, incluindo desempenho de classificação, comparação com baselines e análise de importância de features.

A. Desempenho de Classificação

- **Acurácia:** 93,33%
- **F1-Score Ponderado:** 92,36%

B. Importância das Features

A análise de importância de features (Figura 1) revela os fatores mais críticos para seleção de algoritmos:

TABLE I
TOP 5 FEATURES MAIS IMPORTANTES

Feature	Importância (Gain)
topology_encoded	27,90
v_net_size_ratio	16,06
p_net_enlace_util	1,44
p_net_node_util	1,08
p_net_overall_util	0,79




Fig. 1. Importância das Features no Modelo XGBoost

Insight Chave: Topologia e tamanho relativo da VNR são os fatores dominantes para seleção de algoritmo. A topologia física determina a adequação estrutural de diferentes estratégias de mapeamento, enquanto o tamanho relativo da VNR indica a complexidade do problema. Features de utilização da rede física têm importância secundária mas ainda relevante.

C. Comparação com Baselines

A Tabela II compara a performance do seletor XGBoost contra algoritmos baseline individuais e o oráculo teórico:

TABLE II
COMPARAÇÃO DE PERFORMANCE: XGBOOST VS BASELINES

Método	Taxa Aceitação	Tempo Médio (s)	Categoria
MIP	90,00%	15,02	Fixo
SA-Meta	72,41%	1,31	Fixo
D-Round	47,25%	7,29	Fixo
XGBoost	43,33%	5,63	Dinâmico
RW-Rank-BFS	31,03%	0,34	Fixo
GA-Meta	20,69%	6,77	Fixo
PL-Rank	10,34%	0,64	Fixo
Oráculo	45,00%	5,65	Ótimo

A Figura 2 visualiza a comparação entre métodos:




Fig. 2. Comparação de Taxa de Aceitação e Tempo Médio

A Figura 3 mostra o trade-off entre taxa de aceitação e tempo de execução:




Fig. 3. Trade-off entre Taxa de Aceitação e Tempo de Execução

D. Análise de Resultados

Performance Quase Ótima: O XGBoost alcança 43,33% de taxa de aceitação, apenas 1,67 pontos percentuais abaixo do oráculo teórico (45,00%). Este pequeno gap demonstra que o modelo aprende efetivamente a estratégia de seleção quase ótima, mesmo sem conhecimento perfeito do futuro.

Trade-off Equilibrado: Enquanto MIP alcança a maior taxa de aceitação (90%), seu tempo médio de 15,02s é 2,7× mais lento que XGBoost. Por outro lado, RW-Rank-BFS é o mais rápido (0,34s) mas com taxa de aceitação pobre (31,03%). O XGBoost oferece um meio-termo prático com 5,63s e 43,33% de aceitação.

Superação de Baselines: O seletor dinâmico supera 4 dos 6 algoritmos baseline individuais (RW-Rank-BFS, GA-Meta, PL-Rank e D-Round), demonstrando que a seleção adaptativa combina efetivamente os pontos fortes de múltiplos algoritmos.

Limitações: O XGBoost não supera métodos especializados de alta performance como MIP (90%) e SA-Meta (72,41%). Isto é parcialmente explicado pelo desbalanceamento de classes—MIP representa apenas 0,3% dos dados de treino, limitando a capacidade do modelo de aprender quando selecionar este algoritmo.

Impacto da Topologia: A análise de importância de features revela que topologia é o fator mais crítico (importância 27,90). Isto sugere que diferentes topologias favorecem diferentes algoritmos. Por exemplo, topologias Fat-Tree podem beneficiar mais de algoritmos conscientes de estrutura hierárquica, enquanto topologias Tree podem favorecer heurísticas simples.

Eficiência Computacional: O overhead de predição do XGBoost é negligenciável (<0,01s), tornando a abordagem prática para uso em produção. O tempo médio de 5,63s é dominado pela execução do algoritmo VNE selecionado, não pela fase de predição.

E. Discussão

Os resultados demonstram a viabilidade de seleção dinâmica de algoritmos VNE usando XGBoost. A alta acurácia de classificação (93,33%) traduz-se em performance quase ótima no mundo real, com apenas 1,67% de gap do oráculo. A análise de importância de features fornece insights interpretáveis: topologia e tamanho relativo da VNR direcionam as decisões de seleção.

No entanto, o desbalanceamento de classes permanece como desafio. Classes raras como MIP e GA-Meta têm representação insuficiente, limitando a capacidade do modelo de aprender suas regiões de aplicabilidade. Trabalhos futuros devem focar em estratégias de coleta de dados balanceada, possivelmente através de amostragem dirigida ou geração sintética de VNRs.

A abordagem proposta é complementar a trabalhos existentes em algoritmos VNE. Ao invés de desenvolver um novo algoritmo único, combinamos inteligentemente métodos existentes. Esta estratégia de "ensemble de algoritmos" é conceitualmente similar a ensemble de modelos em machine learning, onde múltiplos modelos fracos combinam-se em um forte.

V. CONCLUSÃO

Este trabalho propôs e avaliou uma abordagem inovadora para Virtual Network Embedding que utiliza XGBoost para selecionar dinamicamente o algoritmo mais apropriado para cada requisição de rede virtual. Através de experimentação extensiva com 800 VNRs únicas, 7 algoritmos VNE e 2 topologias de datacenter, demonstramos que a seleção adaptativa de algoritmos alcança performance quase ótima, ficando apenas 1,67% abaixo do limite teórico superior.

A. Principais Contribuições

Metodologia de Seleção Dinâmica: Desenvolvemos um framework completo que inclui geração de datasets diversificados, engenharia cuidadosa de features sem data leakage, otimização de hiperparâmetros via Grid Search e avaliação rigorosa contra múltiplos baselines.

Alta Acurácia de Predição: O modelo XGBoost alcança 93,33% de acurácia e F1-score ponderado de 92,36%, demonstrando que características da VNR e estado da rede física são suficientes para prever o melhor algoritmo.

Performance Prática: Em simulação de uso real, o seletor dinâmico alcança 43,33% de taxa de aceitação com tempo médio de 5,63s, superando 4 dos 6 algoritmos baseline e oferecendo trade-off equilibrado entre qualidade e velocidade.

Insights Interpretáveis: Análise de importância de features revela que topologia (27,90) e tamanho relativo da VNR (16,06) são os fatores dominantes, fornecendo entendimento interpretável do processo de decisão.

Reprodutibilidade: Todo código fonte, datasets, modelos treinados e scripts de análise foram documentados e organizados para facilitar reprodução e extensão do trabalho.

B. Limitações

Desbalanceamento de Classes: O algoritmo D-Round domina 75% dos dados, enquanto MIP e GA-Meta representam menos de 2% combinados. Isto limita a capacidade do modelo de aprender quando selecionar algoritmos raros.

Cobertura de Topologias: O modelo foi treinado apenas em 2 topologias (Tree e Fat-Tree). Generalização para outras estruturas de rede (GEANT, WX100, topologias reais de ISPs) requer coleta adicional de dados.

Gap de Performance: Embora o XGBoost (43,33%) supere vários baselines, algoritmos especializados como MIP (90%) e SA-Meta (72,41%) ainda apresentam taxas de aceitação superiores. A seleção dinâmica não substitui completamente o melhor algoritmo individual.

Características Estáticas: As features atuais capturam apenas estado instantâneo da rede. Histórico temporal, padrões de chegada de VNRs e previsão de carga futura poderiam melhorar as decisões de seleção.

C. Trabalhos Futuros

Aprendizado Online: Implementar atualização contínua do modelo conforme novas VNRs são processadas. Isto permitiria adaptação a mudanças no padrão de requisições e evolução da rede física.

Amostragem Balanceada: Desenvolver estratégias de coleta de dados que garantam representação adequada de todos os algoritmos, possivelmente através de geração de VNRs sintéticas especificamente desenhadas para favorecer algoritmos raros.

Expansão de Topologias: Treinar modelos em topologias diversas incluindo GEANT, WX100, topologias de ISPs reais e redes de datacenter de larga escala. Transfer learning poderia facilitar adaptação entre topologias.

Otimização Multi-Objetivo: Estender o modelo para considerar explicitamente múltiplos objetivos (aceitação, tempo, custo energético, SLA) através de formulação multi-objetivo ou ensemble de modelos especializados.

Contextual Bandits: Formular seleção de algoritmos como um problema de contextual bandits, balanceando exploração de algoritmos conhecidos com exploração de novas estratégias. Isto permitiria aprendizado de políticas ótimas com garantias teóricas.

Deep Learning: Investigar arquiteturas de redes neurais profundas, especialmente Graph Neural Networks que podem explorar diretamente a estrutura topológica de VNRs e redes físicas.

Confidence-Based Selection: Utilizar probabilidades de predição do XGBoost para recorrer ao MIP quando o modelo está incerto, combinando velocidade de heurísticas com otimalidade de métodos exatos.

Considerações de Energia e SLA: Incorporar restrições de consumo energético e Service Level Agreements como features adicionais e objetivos de otimização, tornando a seleção consciente de sustentabilidade e requisitos contratuais.

D. Impacto Esperado

Esta pesquisa demonstra que seleção inteligente de algoritmos é uma direção promissora para VNE, complementando o desenvolvimento de novos algoritmos individuais. A abordagem proposta pode ser aplicada a outros problemas de otimização de redes onde múltiplos algoritmos complementares existem, incluindo roteamento, balanceamento de carga e orquestração de serviços.

O insight fundamental—que características de problema e estado do sistema determinam a adequação de algoritmos—é transferível para domínios além de VNE. O framework metodológico desenvolvido (geração de datasets, feature engineering, avaliação contra oráculo) pode servir como template para pesquisas futuras em algorithm selection para problemas de rede.

Finalmente, a interpretabilidade do modelo XGBoost fornece valor além de mera predição. A identificação de topologia e tamanho relativo como fatores dominantes sugere direções para design de novos algoritmos que se especializem em cenários específicos, criando um ciclo virtuoso entre desenvolvimento de algoritmos e estratégias de seleção.

REFERÊNCIAS

- [1] L. Gong, Y. Jiang, Y. Wang, Z. Zhu, L. Zhang, X. Liu, and W. Zhao, "Novel algorithm for virtual network embedding: Nutshell framework with extensive analysis," in *2013 Proceedings IEEE INFOCOM*, 2013, pp. 1532–1540.